

粒子群与多种群元胞遗传混合优化算法*

黎明 揭丽琳 鲁宇明

(南昌航空大学 信息工程学院 南昌 330063)

摘 要 元胞遗传算法通过限定个体之间的相互作用邻域提高算法的全局收敛率,但在一定程度降低搜索效率.文中提出一种粒子群与多种群元胞遗传混合优化算法.首先将群体分割成多个相互之间没有邻域关系的元胞子种群,适度降低算法的选择压力,从而更好地保持种群的多样性.算法的变异操作被粒子群算法替代,使得局部搜索能力明显提高.元胞群体分割和粒子群变异较好地均衡全局探索和局部寻优之间的关系.分析混合算法的选择压力和多样性变化规律.实验结果表明,该算法在保证搜索效率较高的同时还显著提高元胞遗传算法的全局收敛率且稳定性得到明显改善.

关键词 元胞遗传算法, 粒子群算法, 种群分割, 选择压力, 多样性
中图法分类号 TP 391.41

A Hybrid Particle Swarm and Multi-Population Cellular Genetic Algorithm

LI Ming, JIE Li-Lin, LU Yu-Ming

(School of Information Engineering, Nanchang Hangkong University, Nanchang 330063)

ABSTRACT

Cellular genetic algorithm (CGA) enhances global convergence rate via constraining individual interaction in its neighbor. However, it results in of low search efficiency. An algorithm, called hybrid particle swarm and multi-population cellular genetic algorithm (HPCGA), is proposed. Firstly, the whole population is divided into some sub-populations, the individuals in different sub-populations do not interact each other. Nevertheless different sub-populations can communicate with each other via immigrant and share the evolutionary information. Division of the population appropriately reduces the selection pressure, and thus the individual diversity is maintained more effectively. The mutation of CGA is replaced by particle swarm optimization to improve the ability of local search. The above two improvements balance the trade-off between global exploration and local exploitation. Selection pressure and individual diversity of the proposed HPCGA are also studied. Optimization of six typical functions is carried out by using the proposed HPCGA and CGA. The experimental results show that the performance of the proposed HPCGA is obviously superior to that of CGA in global convergence rate, convergence speed and stability.

* 国家自然科学基金(No. 60963002)、江西省自然科学基金(No. 2009GZS0090)资助项目

收稿日期:2011-07-25;修回日期:2011-11-01

作者简介 黎明,男,1965年生,教授,博士生导师,主要研究方向为智能计算、模式识别、图像处理. E-mail liming@nchu.edu.cn. 揭丽琳,女,1987年生,硕士研究生,主要研究方向为智能计算. 鲁宇明,女,1969年生,博士研究生,主要研究方向为智能计算.

Key Words Cellular Genetic Algorithm, Particle Swarm Optimization, Population Segmentation, Selection Pressure, Individual Diversity

1 引言

标准遗传算法的个体之间没有位置关系,算法选择个体配对进行交叉变异时,是从整个群体中按一定的规则随机选择出来的,对适应度较高的个体来说,其基因向整个群体中扩散速度可能非常快,这样容易使得种群多样性的过早丢失,导致算法陷入局部最优。元胞遗传算法(Cellular Genetic Algorithm, CGA)是一种将遗传算法和元胞自动机有机结合的算法,它把种群中的每个个体看成是一个元胞,放置在一个空间网格内(一般是一个二维的网格),并且个体的选择、交叉、变异等遗传操作只发生在与其相邻的个体之间。元胞遗传算法具有规则的邻域结构和元胞个体生死状态的自动演化过程,可以做到缓慢地传播适应度高的个体的基因信息,在保持种群多样性方面具有明显优势,改善遗传算法全局收敛性能,已成为解决复杂问题的一种有效方法。

因为元胞遗传算法限定个体之间的位置关系,个体之间信息交流被限制在其邻域范围内,而且生死状态演化过程造成的死亡状态网格也会阻碍个体信息的交流,降低寻优搜索效率,因此元胞遗传算法的优化速度一般较慢。在解决非常复杂的优化问题时,每次评价个体适应度的计算量较大,元胞遗传算法就面临更大的计算速度问题。同时进一步提高元胞遗传算法的全局收敛率也还有很大的研究发展空间。

近年关于元胞遗传算法的研究逐渐增多,但只有少量的研究成果涉及分析混合元胞遗传算法的性能。目前已从演化规则、邻域、灾变、选择压力、元胞分层进化和混合算法等方面对元胞遗传算法进行研究,并取得一定的研究成果。

文献[1]、文献[2]研究元胞遗传算法的演化规则,通过改变演化规则对个体基因扩展速度进行调节。文献[3]~文献[5]描述和研究最常用的邻域结构。文献[3]、文献[6]根据群体平均适应度和熵来自适应调整邻域结构形状和大小。文献[7]的研究表明不同邻域产生的模拟结果和空间形态方面呈现显著差异。文献[8]、文献[9]在元胞遗传算法中引入灾变机制,进化一定代数后随机在某个元胞区域引入灾变,起到保持群体多样性的目的。文献[10]~文献[12]对元胞遗传算法的选择压力进行

研究,分析不同邻域类型、不同个体繁殖策略、不同选择方法下元胞遗传算法选择压力的变化情况。文献[13]对分层的元胞遗传算法进行分析,文献[14]、文献[15]提出一种混合的元胞分布估计算法。文献[16]、文献[17]将类似的算法应用到复杂多目标的优化问题求解。

本文结合元胞自动机和遗传算法的特点,从完全不同的角度研究如何提高元胞遗传算法的全局探索能力和局部寻优能力的平衡度。借鉴粒子群算法的思想,本文提出一种粒子群与多种群元胞遗传混合优化算法(Hybrid Particle Swarm and Multi-Population Cellular Genetic Algorithm, HPCGA)。首先将群体分割成多个元胞子种群,子种群之间相互通信共享进化信息,对元胞网格的分割适度降低遗传算法的选择压力,能更好保持种群的多样性。算法的变异操作被粒子群算法替代,进而提高局部搜索能力,粒子群变异减轻由于选择压力降低造成的收敛速度降低的问题。提出的 HPCGA 算法在全局探索和具备寻优之间达到较好平衡。最后对该算法进行选择压力分析和群体多样性分析,并通过对 6 个典型函数的优化结果分析,验证该算法在全局收敛率和收敛速度的方面的良好性能。

2 粒子群与多种群元胞遗传混合优化算法原理及实现

2.1 元胞遗传算法和粒子群算法的基本概念

元胞遗传算法^[3]将元胞自动机的原理与遗传算法相结合,是遗传算法的一个分支,群体中具有遗传性质的所有个体分布在空间网格内,个体只与其相邻的个体发生相互作用。元胞、元胞空间、元胞演化规则是元胞自动机最重要的组成部分,其中元胞和元胞空间仅表示元胞自动机系统的静态成分,而演化规则体现系统的动态过程,可更为有效地模拟生物在自然界生物生死状态的动态演化。由于元胞在下一时刻的生死状态是由该元胞当前的状态及其所有邻域元胞的状态来决定的,所以在指定演化规则之前,首先要定义一种邻域规则,确定哪些元胞属于该元胞的邻居。本文中的元胞邻域采用 Moore 邻域类型,即一个元胞的上、下、左、右、左上、右上、左下、右下相邻 8 个元胞为该元胞的邻居,邻域半径为 1。

演化规则是定义在空间局部范围内的,是元胞自动机的核心,演化规则不同产生千差万别的变化.由数学家 Conway 开发出的生命游戏规则^[18]近似地模拟生物群体的生存、竞争、灭绝等复杂现象及规律,如果一个元胞周围的活元胞数目太少的话,会因为个体之间缺乏相互作用而导致出现生命危机;如果周围的活元胞数目太多,个体相互之间的竞争加剧,生存和繁殖的机会减少.本文采用这种生命游戏演化规则,其数学表达式参见文献[18].

粒子群算法(Particle Swarm Optimization, PSO)是受鸟群和鱼群运动的行为方式启发而提出的一种具有代表性的群集智能优化方法. PSO 初始化一群随机粒子,通过迭代搜寻最优值.在 D 维空间 n 个粒子组成粒子群,每个粒子都可能是 D 维搜索空间中的一个解.在每次迭代中,粒子通过跟踪两个“极值”,即个体迄今最优位置和全局迄今最优位置来动态更新进化的速度和位置.

2.2 元胞种群的分割与元胞子种群间个体迁移

本文从维护种群多样性的角度出发,将 CGA 算法的种群均匀分成若干个元胞子种群,每个元胞子种群独立进化,每隔一定的进化代数发生个体迁移进行进化信息交换,目的是为了避免因种群的分割而造成无联系的进化孤岛,从而整体上实现各子种群间的相互通信及并行进化.

当进化代数满足一定条件时,各个元胞子种群之间的个体以一定的迁移率发生迁移,即从元胞子种群中按迁移率比例随机选择若干个网格位置,采用网格位置一一对应的方式在多个元胞子种群之间将这些网格上的个体随机进行交换.

2.3 构造新的粒子群变异算子

现有的元胞遗传算法实施的是随机变异操作,既与历史状态和当前状态无关,也不考虑与最优解之间的距离.因此变异概率过大会造成遗传模式的破坏,过小则又会使搜索过程缓慢甚至停滞不前,加上变异操作的无方向性容易导致变异产生的新个体因适应度低而被迅速淘汰.针对这个问题本文提出元胞遗传算法的粒子群变异算子.

设元胞种群表示为

$$Q_i = \{x_{i1}, x_{i2}, \dots, x_{iN_i}\}, 1 \leq i \leq N,$$

其中, N 为种群规模, i 表示个体在元胞网格中的位置, t 表示进化代数, x_{it} 表示元胞网格中第 i 个位置上个体的基因编码矢量.以实数遗传基因编码为例,则 x_{it} 为实数矢量.

设 $x_{i \max}^{\text{History}}$ 是网格 i 位置上在进化历史过程中迄今为止适应度最高个体基因编码矢量, $x_{i \max}^{\text{Neighbor}}$ 是网

格 i 位置邻域在进化历史过程中迄今为止适应度最高个体基因编码矢量,则粒子群变异算子:

$$V_{i(t+1)} = WV_{it} + C_1\gamma_1(x_{i \max}^{\text{History}} - x_{it}) + C_2\gamma_2(x_{i \max}^{\text{Neighbor}} - x_{it}),$$

$$V_{i(t+1)} = \begin{cases} V_{\min}, & \text{if } V_{i(t+1)} < V_{\min} \\ V_{\max}, & \text{if } V_{i(t+1)} > V_{\max} \\ V_{i(t+1)}, & \text{if } V_{\min} \leq V_{i(t+1)} \leq V_{\max} \end{cases}$$

$$x_{i(t+1)} = x_{it} + V_{i(t+1)},$$

其中, V_{it} 和 $V_{i(t+1)}$ 分别是网格 i 位置上个体在第 t 代和第 $t+1$ 代的变异速度, W 表示惯性权重, C_1 表示自身学习的因子, C_2 表示个体向社会学习的因子, γ_1 和 γ_2 是 $[0,1]$ 区间均匀分布的随机数, V_{\min} 和 V_{\max} 用来限制个体变异的最小和最大速度.构造的新粒子群变异算子使变异操作不再是一般元胞遗传算法中简单的随机变异,而是一种具备自学习能力的变异算子,使得元胞遗传算法的局部寻优能力得到提高.

2.4 粒子群与多种群元胞遗传混合优化算法步骤

step 1 产生初始化种群,参数初始化,将种群均匀分割为多个同等大小的元胞子种群.

step 2 个体依次放置于空间网格内,并随机确定元胞的生存与死亡状态.

step 3 各个元胞子种群独立进化,依次以每个元胞网格位置作为中心,进行生命游戏的演化,确定该元胞网格位置在下一时刻的生死状态.

step 4 依次以每个活状态元胞网格位置作为中心选择元胞邻域,在邻域中根据个体适应度大小按照轮盘赌选择方法选择一个个体与中心位置个体进行遗传交叉运算.

step 5 对遗传交叉新产生的个体实施新的粒子群变异运算,变异后个体如果适应度得到提高则替代其父代个体.

step 6 每隔一定进化代数实施各子种群之间个体迁移.

step 7 若算法收敛或者达到最大进化代数时结束,否则转向 step 3.

step 8 输出当前最优解.

3 算法理论与实验分析

3.1 实验函数

6 种典型的测试函数具体如下,对每个函数都给出它们的最优值.

1) Griewangk's Function (F_1)

$$f(x_1, x_2, \dots, x_n) = 1 - \left(\frac{1}{4000} \sum_{i=1}^n x_i^2 - \prod_{i=1}^n \cos\left(\frac{x_i}{\sqrt{i}}\right) \right),$$

$-10 \leq x, y \leq 10$.

该函数只有当 $x_i = 0$ 时达到全局最大值点, 最大值为 2; 当

$x_i = \pm k\pi\sqrt{i}, i = 1, 2, \dots, n; k = i = 1, 2, \dots, n$, 达到局部极大值.

2) Schaffer' f6 Function (F_2)

$$f(x_1, x_2, \dots, x_n) = 0.5 - \frac{\left(\sin \sqrt{\sum_{i=1}^n x_i^2}\right)^2 - 0.5}{\left(1 + 0.0001 \sum_{i=1}^n x_i^2\right)^2},$$

$-10 \leq x, y \leq 10$.

该函数有无数个局部极大值, 但是只有当 $x_i = 0$ 时为全局最大值点, 最大值为 1. 其二维函数图形呈现同心圆形波纹状, 最大值在中心处, 周围有一堵由局部极小值构成的围墙将最大值点包围在内, 外围又是局部极大值点, 所以该函数很不容易找到最大值点, 一般算法很容易陷入局部极值, 极具欺骗性.

3) Easom Function (F_3)

$$\begin{aligned} f(x_1, x_2) = & -\cos x_1 \cos x_2 \exp(-((x_1 - \pi)^2 + (x_2 - \pi)^2)), \\ & -100 \leq x_1, x_2 \leq 100; \\ f(x_1, x_2, \dots, x_n) = & -\prod_{i=1}^n \cos x_i \exp(-\sum_{i=1}^n (x_i - \pi)^2), \\ & -100 \leq x_1, x_2, \dots, x_n \leq 100. \end{aligned}$$

该函数 $x_i = \pi$ 时达到全局最小值点, 有一个全局最小值 -1.

4) 多峰函数(F_4)

$$\begin{aligned} f(x, y) = & 4 - (x^2 + 2y^2 - 0.4\cos(3\pi x) - 0.6\cos(4\pi y)), \\ & -10 \leq x, y \leq 10. \end{aligned}$$

该函数有一个 (0, 0) 点是全局最大值点, 最大值为 5. 该函数是一个多峰函数, 所以搜索算法很容易陷入某个局部极大值点. 由于该函数的这种特性, 所以常被用来检测搜索算法的性能.

5) Hansen Function (F_5)

$$\begin{aligned} f(x, y) = & \sum_{i=1}^5 i \cos[(i-1)x + i] \sum_{i=1}^5 i \cos[(i+1)y + i], \\ & -10 \leq x, y \leq 10. \end{aligned}$$

该函数共有 760 个局部极小值, 其中 9 个点个全局最小值点, 其全局最小值为 -176.541793.

6) Shubert Function (F_6)

$$\begin{aligned} f(x, y) = & \sum_{i=1}^5 i \cos[(i+1)x + i] \sum_{i=1}^5 i \cos[(i+1)y + i], \\ & -10 \leq x, y \leq 10. \end{aligned}$$

该函数是一个无穷多密集尖峰的多模态函数, 共有 760 个局部最小点, 其中 18 个点是全局最小点, 其全局最小值为 -186.7309.

在实验中对上述 6 组函数进行优化来评估本文算法的性能, 每组实验算法都分别独立运行 100 次. 测试中算法的参数设置如下. 总种群大小为 400, 元胞网格大小为 20×20 , 采用实值编码, 交叉率为 0.8, CGA 算法中变异概率为 0.05, HPCGA 中子种群数目为 4, 采用均匀分割, 每个子种群个体数目为 100, 不同子群体之间的迁移率设置为 0.2, 惯性权重 $W = 1$, 学习因子 $C_1 = C_2 = 2$.

种群的总规模与被优化的目标函数有关, 目标函数的维数越高、寻优难度越高, 则需要的种群规模越大. 对上述 6 个典型函数的实验表明, 种群大小小于 400 则全局收敛率逐步开始下降, 大于 400 则变化不大. HPCGA 中子种群数目选择较复杂, 也与被优化的目标函数有一定关系, 并与总群体规模有关. 由实验比较所得, 对上述 6 个典型目标函数, HPCGA 中子种群数目选择为 4 ~ 8 时效果最好. 交叉率和变异概率的选择参见文献[19]. 不同子群体之间的迁移率可微调个体基因在基因池中的扩散速度, 迁移率过小时子群体之间趋于隔绝, 失去种群分割的意义, 迁移率过大时造成基因扩散速度加快, 对保持群体多样性不利. 惯性权重 W 和学习因子 C_1 和 C_2 是粒子群算法的基本控制参数, 本文选择的是典型的取值.

3.2 种群分割与新的粒子群变异算子的性能分析

从全局收敛率、平均收敛代数、收敛时间、平均最优值、最优值、最优解方差等方面进行统计记录, 其中, 平均收敛代数是指对同一目标函数重复进行寻优实验 (100 次) 得到的收敛时进化代数的平均值. 全局收敛率是指对同一目标函数重复进行优化实验, 算法收敛到全局最优解的次数与实验重复次数之比. 收敛时间是指对同一目标函数重复进行寻优实验, 算法收敛时所需要的时间平均值. 平均最优值是指对同一目标函数重复进行寻优实验得到的最优值的平均值. 对 $F_3 \sim F_6$ 函数在低维 (2 维) 下的实验结果如表 1 所示.

实验结果表明无论从平均收敛代数、全局收敛率、收敛时间还是均值、最优值、最优解方差等方面, 本文的 HPCGA 都有较好效果. HPCGA 算法的平均收敛代数更少, 收敛速度更快, 平均最优值更接近于全局最优值. 特别是最优解方差比 CGA 算法更小, 即 HPCGA 算法比 CGA 算法更稳定.

表 1 低维目标函数 CGA 与 HPCGA 实验结果对比

Table 1 Experimental result comparison of CGA and HPCGA for low dimensional objective function

| 目标函数 | 维数 | 算法 | 平均收敛代数 | 全局收敛率/% | 收敛时间/s | 平均最优值 | 最优值 | 最优解方差 |
|----------------|----|-------|--------|---------|--------|-----------|-----------|----------|
| F ₃ | 2 | CGA | 84.7 | 89 | 1.058 | -0.9998 | -1.0000 | 2.64e-06 |
| | | HPCGA | 72.9 | 96 | 1.054 | -1.0000 | -1.0000 | 1.32e-13 |
| F ₄ | 2 | CGA | 56.1 | 98 | 0.694 | 5.0000 | 5.0000 | 1.35e-12 |
| | | HPCGA | 28.9 | 100 | 0.453 | 5.0000 | 5.0000 | 0 |
| F ₅ | 2 | CGA | 117.0 | 46 | 1.547 | -176.5320 | -176.5418 | 4.72e-04 |
| | | HPCGA | 67.3 | 72 | 1.091 | -176.5405 | -176.5418 | 8.04e-06 |
| F ₆ | 2 | CGA | 122.6 | 35 | 1.579 | -186.7104 | -186.7309 | 1.60e-03 |
| | | HPCGA | 75.6 | 70 | 1.216 | -186.7280 | -186.7309 | 1.42e-04 |

表 2 高维目标函数 CGA 与 HPCGA 实验结果对比

Table 2 Experimental result comparison of CGA and HPCGA for high dimensional objective function

| 目标函数 | 维数 | 算法 | 平均收敛代数 | 全局收敛率/% | 收敛时间/s | 平均最优值 | 最优值 | 最优解方差 |
|----------------|----|-------|--------|---------|--------|---------|---------|----------|
| F ₁ | 10 | CGA | 858.9 | 43 | 13.184 | 1.9996 | 2.0000 | 1.84e-06 |
| | | HPCGA | 35.7 | 99 | 0.727 | 2.0000 | 2.0000 | 5.36e-10 |
| | 20 | CGA | 1913.0 | 4 | 34.768 | 1.9998 | 1.9999 | 6.42e-09 |
| | | HPCGA | 38.5 | 100 | 1.017 | 2.0000 | 2.0000 | 2.34e-16 |
| | 30 | CGA | 1920.0 | 3 | 40.495 | 1.9982 | 1.9992 | 2.13e-07 |
| | | HPCGA | 29.2 | 100 | 0.888 | 2.0000 | 2.0000 | 3.90e-14 |
| F ₂ | 10 | CGA | 310.3 | 10 | 11.487 | 0.9980 | 0.9998 | 3.48e-07 |
| | | HPCGA | 111.5 | 99 | 5.777 | 0.9997 | 0.9998 | 3.83e-08 |
| | 20 | CGA | - | 0 | - | 0.9977 | 0.9978 | 4.42e-07 |
| | | HPCGA | 122.4 | 94 | 8.329 | 0.9996 | 0.9998 | 2.18e-07 |
| | 30 | CGA | - | 0 | - | 0.9976 | 0.9978 | 7.22e-07 |
| | | HPCGA | 145.1 | 89 | 11.516 | 0.9993 | 0.9998 | 5.45e-07 |
| F ₃ | 10 | CGA | - | 0 | - | 0 | 0 | - |
| | | HPCGA | 510.5 | 73 | 9.452 | -0.9876 | -0.9998 | 4.66e-04 |

对 F₁ ~ F₃ 函数在高维下的实验结果如表 2 所示。一般而言,目标函数维数的增加,优化难度也随之加大,对优化算法的性能要求越高.正如表 2 结果显示,随着维数的不断增加,CGA 与 HPCGA 从运行时间及平均收敛代数方面都有所增加.但 HPCGA 总体性能在高维情况下更显示出其优越性.对 F₁ 函数而言,CGA 算法运行时间及平均收敛代数是 HPCGA 算法的几十倍,且 HPCGA 算法的全局收敛率保持在 99% 左右,避免早熟收敛的能力非常强. CGA 优化 20 维、30 维的 F₂ 函数和优化 10 维的 F₃ 函数时几乎找不到最优解,而 HPCGA 算法全局收率都超过 70% 以上.表中的数据还显示,运行 100 次 HPCGA 所得到最优解集的方差明显小于 CGA 结果,说明 HPCGA 对高维函数优化的稳定性能也是非常优秀的.

综合表 2 和表 3 实验结果对比分析可知,HPCGA 对低维和高维函数优化的全局收敛率、收敛速度和求解的稳定性明显优于 CGA.

3.3 选择压力分析

全局探索与局部寻优的平衡关系是算法的核心,而选择压力实际上反映着这两者之间的平衡度,

选择压力过高可能会使算法快速收敛于一个局部最优解,导致找不到全局最优解;过低又会使适应度高的个体在种群中的影响降低,以致算法不能收敛.

本文采用文献[3]提出的占据时间来度量选择压力.设定元胞网格中所有位置上个体都处于生的状态,并去除元胞生死演化的影响,同时去除元胞遗传算法变异运算的影响.设定网格中心位置有一个适应度为 1 的个体,其他网格位置上个体适应度均为 0,只对元胞个体进行选择运算,适应度为 1 的个体占据整个群体的进化代数被定义为占据时间.占据时间曲线是以算法运行的代数为横坐标,以种群中最优个体占据整个种群的百分比为纵坐标.通过对占据时间曲线的观察就可判断出元胞遗传算法选择压力的变化.

CGA 占据时间曲线和 HPCGA 占据时间曲线分别如图 1 所示,在 CGA 的进化过程中优秀个体在 10 代左右就能迅速占满种群,而 HPCGA 的进化过程中优秀个体在 20 代(是 CGA10 代的 2 倍)以后还不能完全占据种群,表示 HPCGA 的选择压力较 CGA 有所下降,有利于种群多样性的保持.这里没有考虑交叉和变异算子的影响,因此图 1 说明 HPCGA 的

种群分割策略较为明显地降低算法的选择压力,因此可较为明显地提高 CGA 的全局收敛率.选择压力小必然降低收敛速度,因此也说明如果没有 HPCGA 的粒子群变异算子的加速作用,就得不到表 1 和表 2 中 HPCGA 的收敛速度快的优势.




图 1 2 种方法占据时间曲线对比
Fig. 1 Occupation time comparison of 2 methods

3.4 种群多样性分析

维持种群多样性是提高遗传算法全局探索能力的最重要手段之一,本节分析 HPCGA 在进化过程中种群多样性的变化规律,采用遗传群体的熵度量种群的多样性.

设元胞群体为 $Q = \{x_1, x_2, \dots, x_N\}, 1 \leq i \leq N$, 每个个体基因矢量 x_i 具有 M 维编码,参见文献[20],根据信息论熵的定义,遗传群体的熵 H 等于各位编码(基因)熵 $H_j: j = 1, 2, \dots, M$ 的总和:

$$H = \frac{\sum_{j=1}^M H_j}{M}, \quad H_j = \sum_{i=1}^M \sum_{k=i+1}^M (-P_{ik} \log P_{ik}),$$

其中, P_{ik} 是第 i 个个体的第 j 维编码与第 k 个个体的第 j 维编码的相似程度,即

$$P_{ik} = 1 - \frac{|x_j(i) - x_j(k)|}{B_j - A_j},$$

其中, A_j, B_j 是 x_i 第 j 维编码的边界,也就是目标函

数第 j 维的搜索范围.
采用 CGA 和 HPCGA 对 10 维的 F_2 函数进行 100 次优化,图 2 分别是 CGA 和 HPCGA 平均种群熵值在进化过程中的变化曲线.图 2 显示 CGA 种群多样性下降迅速,在 250 代左右下降到非常低,而 HPCGA 种群多样性下降较缓慢,始终维持在较好的水平.这也说明 HPCGA 种群分割明显提升种群多样性,但采用粒子群变异算子代替 CGA 的传统变异算子后,在加快算法收敛速度的同时并没有对种群多样性保持能力产生明显影响.

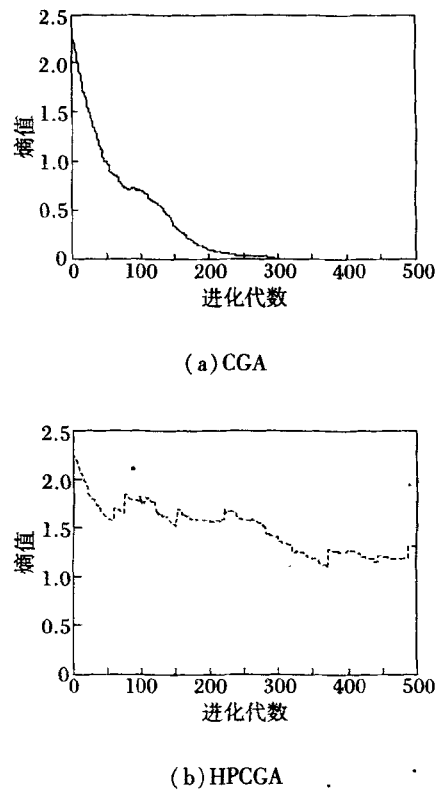


图 2 2 种方法平均种群熵值在进化过程中的变化曲线
Fig. 2 Average population entropy changing procedure of 2 methods

4 结 束 语

本文结合遗传算法和元胞自动机的原理,将粒子群算法思想引入元胞遗传算法,提出一种粒子群与多种群元胞遗传混合优化算法.该算法采用种群分割方法,选择合适的迁移策略,较好地保持种群多样性.并利用粒子群算法构造新的变异算子代替传统的变异操作,避免随机性和盲目性,有效解决一般元胞遗传算法搜索效率偏低的问题.算法选择压力分析结果、群体多样性分析结果和优化典型测试函

数问题的结果表明, HPCGA 在全局收敛率、收敛速度方面都有明显提高, 较好平衡全局探索能力和局部寻优能力, 而且稳定性得到显著改善, 扩展元胞遗传算法的应用范围. 将 HPCGA 的元胞群体分割方法和粒子群变异方法应用到文献[1]、[17]所述的其它对 CGA 的改进算法中同样可进一步提高这些改进元胞遗传算法的全局收敛能力和收敛速度.

需要进一步研究的有两个方面: 1) 如何根据优化的目标函数不同以及在进化过程的不同阶段自适应地控制元胞群体分割, 包括将元胞群体分割为多少个子种群更为合适, 子种群的元胞网格形状如何变化等; 2) 理论分析粒子群与多种群元胞遗传混合优化算法的收敛性.

参 考 文 献

- [1] Zhang Yu, Li Ming, Lu Yuming. Study on Evolution Rules of Optimization Genetic Algorithm with Cellular Automata. Application Research of Computers, 2009, 26(10): 1-4 (in Chinese)
(张俞, 黎明, 鲁宇明. 元胞遗传算法演化规则的研究. 计算机应用研究, 2009, 26(10): 1-4)
- [2] Lu Yuming, Li Ming, Li Ling. The Cellular Genetic Algorithm with Evolutionary Rule. Acta Electronica Sinica, 2010, 38(7): 1603-1607 (in Chinese)
(鲁宇明, 黎明, 李凌. 一种具有演化规则的元胞遗传算法. 电子学报, 2010, 38(7): 1603-1607)
- [3] Alba E, Dorronsoro B. Cellular Genetic Algorithms. New York, USA: Springer, 2008
- [4] Sarma J, de Jong K A. An Analysis of the Effect of the Neighborhood Size and Shape on Local Selection Algorithms // Proc of the International Conference on Evolutionary Computation. Berlin, Germany, 1996: 236-244
- [5] Hisao I, Noritaka T, Yusuke N. Examining the Effect of Elitism in Cellular Genetic Algorithms Using Two Neighborhood Structures // Proc of the 10th International Conference on Parallel Problem Solving from Nature. Dortmund, Germany, 2008: 458-467
- [6] Chen Bingrui, Feng Xiating. Self-Adapting Chaos-Genetic Hybrid Algorithm with Mixed Congruential Method // Proc of the 4th International Conference on Natural Computation. Jinan, China, 2008, VII: 674-677
- [7] Feng Yongjiu, Han Zhen. Impact of Neighbor Configurations on Spatially-Explicit Modeling Results. Geographical Research, 2011, 30(6): 1-11 (in Chinese)
(冯永玖, 韩震. 元胞邻域对空间直观模拟结果的影响. 地理研究, 2011, 30(6): 1-11)
- [8] Kirley M. A Cellular Genetic Algorithm with Disturbance: Optimization Using Dynamic Spatial Interactions. Journal of Heuristics, 2002, 8(3): 321-342
- [9] Lu Yuming, Li Ming, Li Ling, et al. Improved Genetic Algorithm Based on Migration Differential Individuals. Systems Engineering and Electronics, 2011, 33(3): 1-4 (in Chinese)
(鲁宇明, 黎明, 李凌, 等. 基于个体差异移民的改进元胞遗传算法. 系统工程与电子技术, 2011, 33(3): 1-4)
- [10] Jiradej V, Nasimul N, Hitoshi I. Polynomial Selection: A New Way to Tune Selective Pressure // Proc of the 2nd World Congress on Nature and Biologically Inspired Computing. Kitakyushu, Japan, 2010: 597-602
- [11] Kaveh A, Shahrouzi M. Dynamic Selective Pressure Using Hybrid Evolutionary and Ant System Strategies for Structural Optimization. International Journal for Numerical Methods in Engineering, 2008, 73(4): 544-563
- [12] Camargo G, Camargo J, Naufal J, et al. Definition of Selective Pressure Control Methods for Optimization of Genetic Algorithms in Air Traffic Control // Proc of the 10th International Conference on Artificial Intelligence and Soft Computing. Zakopane, Poland, 2006: 304-311
- [13] Janson S, Alba E, Dorronsoro B, et al. Hierarchical Cellular Genetic Algorithm // Proc of the 6th European Conference on Evolutionary Computation in Combinatorial Optimization. Budapest, Hungary, 2006: 111-122
- [14] Sun Jianyong, Zhang Qingfu, Li Jin, et al. A Hybrid Estimation of Distribution Algorithm for CDMA Cellular System Design // Proc of the 6th International Conference on Simulated Evolution and Learning. Hefei, China, 2006: 905-912
- [15] Muhlenbein H, Paass G. From Recombination of Genes to the Estimation of Distributions // Proc of the Ada-Europe International Conference on Reliable Software Technologies. Uppsala, Sweden, 1996: 178-187
- [16] Jolai F, Assadipour G. A Hybrid Cellular Genetic Algorithm for Multi-Objective Crew Scheduling Problem // Proc of the 5th International Conference on Hybrid Artificial Intelligence Systems. San Sebastián, Spain, 2010: 359-367
- [17] Durillo J J, Nebro A J, Luna F, et al. Solving Three-Objective Optimization Problems Using a New Hybrid Cellular Genetic Algorithm // Proc of the 10th International Conference on Parallel Problem Solving from Nature. Dortmund, Germany, 2008: 661-670
- [18] Beata C, Michel D. Cellular Automata Modeling of Physical Systems. Cambridge, UK: Cambridge University Press, 1998
- [19] Eiben A E, Hinterding R, Michalewicz Z. Parameter Control in Evolutionary Algorithms. IEEE Trans on Evolutionary Computation, 1999, 3(2): 124-141
- [20] Yang Xiaoqin, Li Ming, Zhou Linxia. Entropy Based Genetic Algorithm with Dual Subpopulations. Pattern Recognition and Artificial Intelligence, 2005, 18(3): 286-290 (in Chinese)
(杨小芹, 黎明, 周琳霞. 基于熵的双群体遗传算法研究. 模式识别与人工智能, 2005, 18(3): 286-290)

作者： 黎明， 揭丽琳， 鲁宇明， [LI Ming](#)， [JIE Li-Lin](#)， [LU Yu-Ming](#)
作者单位： [南昌航空大学 信息工程学院 南昌 330063](#)
刊名： [模式识别与人工智能](#) 
英文刊名： [Pattern Recognition and Artificial Intelligence](#)
年， 卷(期)： 2012, 25 (4)

参考文献(20条)

1. [张俞;黎明;鲁宇明 元胞遗传算法演化规则的研究\[期刊论文\]-计算机应用研究 2009\(10\)](#)
2. [鲁宇明;黎明;李凌 一种具有演化规则的元胞遗传算法\[期刊论文\]-电子学报 2010\(07\)](#)
3. [Alba E;Dorransoro B Cellular Genetic Algorithms 2008](#)
4. [Sarma J;de Jong K A An Analysis of the Effect of the Neighborhood Size and Shape on Local Selection Algorithms 1996](#)
5. [Hisao I;Noritaka T;Yusuke N Examining the Effect of Elitism in Cellular Genetic Algorithms Using Two Neighborhood Structures 2008](#)
6. [Chen Bingrui;Feng Xiating Self-Adapting Chaos-Genetic Hybrid Algorithm with Mixed Congruential Method 2008](#)
7. [冯永玖;韩震 元胞邻域对空间直观模拟结果的影响\[期刊论文\]-地理研究 2011\(06\)](#)
8. [Kirley M A Cellular Genetic Algorithm with Disturbance:Optimization Using Dynamic Spatial Interactions 2002\(03\)](#)
9. [鲁宇明;黎明;李凌 基于个体差异移民的改进元胞遗传算法\[期刊论文\]-系统工程与电子技术 2011\(03\)](#)
10. [Jiradej V;Nasimul N;Hitoshi I Polynomial Selection:A New Way to Tune Selective Pressure 2010](#)
11. [Kaveh A;Shahrouzi M Dynamic Selective Pressure Using Hybrid Evolutionary and Ant System Strategies for Structural Optimization\[外文期刊\] 2008\(04\)](#)
12. [Camargo G;Camargo J;Naufal J Definition of Selective Pressure Control Methods for Optimization of Genetic Algorithms in Air Traffic Control 2006](#)
13. [Janson S;Alba E;Dorransoro B Hierarchical Cellular Genetic Algorithm 2006](#)
14. [Sun Jianyong;Zhang Qingfu;Li Jin A Hybrid Estimation of Distribution Algorithm for CDMA Cellular System Design 2006](#)
15. [Muhlenbein H;Paass G From Recombination of Genes to the Estimation of Distributions 1996](#)
16. [Jolai F;Assadipour G A Hybrid Cellular Genetic Algorithm for Multi-Objective Crew Scheduling Problem 2010](#)
17. [Durillo J J;Nebro A J;Luna F Solving Three-Objective Optimization Problems Using a New Hybrid Cellular Genetic Algorithm 2008](#)
18. [Beastin C;Michel D Cellular Automata Modeling of Physical Systems 1998](#)
19. [Eiben A E;Hinterding R;Michalewicz Z Parameter Control in Evolutionary Algorithm\[外文期刊\] 1999\(02\)](#)
20. [杨小芹;黎明;周琳霞 基于熵的双群体遗传算法研究\[期刊论文\]-模式识别与人工智能 2005\(03\)](#)

本文链接: http://d.wanfangdata.com.cn/Periodical_mssbyrgzn201204008.aspx