

文章编号: 1001-0920(2010)03-0404-07

基于两阶段领导的多目标粒子群优化算法

胡广浩^a, 毛志忠^{a,b}, 何大阔^{a,b}

(东北大学 a. 信息科学与工程学院, b. 流程工业综合自动化教育部重点实验室, 沈阳 110004)

摘要: 提出一种基于两阶段领导的多目标粒子群算法 (P-AMOPSO). 该算法包含 4 个改进策略: 基于强支配排序与拥挤距离排序相结合的构造外部集策略, 基于两阶段的领导粒子选择策略, 基于高斯分布及均匀分布相结合的变异策略, 基于邻域认知的个体极值更新策略. 通过几个典型的多目标测试函数对 P-AMOPSO 算法的性能进行测试, 并与多目标优化算法进行对比. 结果表明, P-AMOPSO 算法具有较好的搜索性能.

关键词: 粒子群算法; 多目标优化; 两阶段领导; 变异

中图分类号: TP202.7

文献标识码: A

Multi-objective PSO optimization algorithm based on two stages-guided

HU Guang-hao^a, MAO Zhi-zhong^{a,b}, HE Da-kuo^{a,b}

(a. College of Information Science and Engineering, b. Key Laboratory of Integrated Automation of Process Industry, Ministry of Education, Northeastern University, Shenyang 110004, China. Correspondent: HU Guang-hao, E-mail: guanghao5566@126.com)

Abstract: This paper introduces a multi-objective particle swarm optimization algorithm (P-AMOPSO) based on two stages-guided, which includes four improved strategies, the strategy of constructing external data set based on combining strong predominance ranking and crowding distance ranking, the strategy of selecting guided particle based on two stages, the strategy of mutation based on combining Gaussian distribution mutation and uniform distribution mutation, and the strategy of updating based on personal best of neighborhood consciousness. Some benchmark functions are tested for comparing the performance of P-AMOPSO. The results show the better search performance of P-AMOPSO.

Key words: PSO; Multi-objective optimization; Two stages-guided; Mutation

1 引言

科学研究与工程实践中存在大量的多目标优化问题 (MOP), 且其各目标之间通常相互制约, 对其中一个目标优化必须以其他目标为代价, 因此很难评价多目标问题解的优劣性. 所以, 多目标优化问题的最优解往往不是单一的, 而是一组解的集合. 基于种群的进化算法具有隐含的并行特征, 可在单轮模拟过程中得到多个解, 较适合求解多目标优化问题.

粒子群算法 (PSO) 具有高速收敛和易于实现的特点, 适合扩展并应用于多目标优化问题的求解^[1-13]. 文献[1]提出基于快速非支配排序的多目标粒子群 (MOPSO) 算法, 该算法通过比较粒子的当前位置与局部最优位置的支配关系, 保证粒子向

Pareto 最优前沿的进化; [2] 提出基于强度 Pareto 进化算法的环境选择与配对选择策略的 MOPSO 方法; [3] 采用粒子群分割策略, 对子群体根据不同进化方向设置不同的全局最优值, 实现了粒子群的多方向进化; [4] 提出了基于动态交换策略的快速 MOPSO; [5] 通过将档案维护和全局最好位置选取结合在一起, 提出了 Pareto 档案 MOPSO 算法; [6] 利用外部粒子群指导该群体外其他粒子的飞行, 并直接利用 Pareto 档案进化策略 (PAES) 中的方法对外部粒子群进行维护; [7] 提出一种非劣排序 PSO, 通过将非劣排序遗传算法的主要搜索过程移植到 PSO 中, 取得了同遗传算法相当的搜索性能; [8] 完成了向量估计粒子群算法的并行实现, 设计了一种

收稿日期: 2009-05-15; 修回日期: 2009-08-26.

基金项目: 国家 863 计划项目 (2006AA060201).

作者简介: 胡广浩 (1983 →), 男, 辽宁鞍山人, 博士生, 从事工业过程建模与优化的研究; 毛志忠 (1961 →), 男, 山东莱州人, 教授, 博士生导师, 从事复杂过程建模与优化等研究.

并行向量估计粒子群算法,这是关于 MOPSO 并行化较早的研究成果;[9]提出了在支配一个粒子外部集的个体中为该粒子选取其全局极值的优化策略;[10]提出了最优解评估选取的算法;[11]提出的 EM-MOPSO 采用了新的外部集处理方法和变异方法,在兼备已有算法优势的基础上,通过引入新的外部集处理和变异方法使计算时间大大缩减,在处理两个目标的优化问题时也有较好的效果;[12]提出一种基于拥挤度与变异的动态微粒群多目标优化算法,领导粒子从拥挤度大的一些非劣解中选取,但其变异带有盲目性;[13]提出一种基于多子群的方法,该方法采用代与代之间的全优、半优、全劣的关系构造子集,并从中选出领导粒子,但仿真表明该算法收敛速度较慢.由上述文献可以看出,目前的多目标粒子群算法,若注重收敛速度,则解的均匀多样性较差;若注重解的均匀性,则收敛速度缓慢.

为了提高微粒群多目标算法的收敛性及收敛速度,增加非劣解的均匀多样性,本文提出一种基于两阶段领导的新型多目标粒子群优化算法(P-AMOPSO).在算法运行中包含 4 种改进策略:基于强支配排序与拥挤距离排序相结合的策略构造外部集,基于两阶段领导粒子选择策略,基于高斯分布及均匀分布相结合的变异策略,基于邻域认知的个体极值更新策略.通过对测试函数的仿真分析,验证了新算法的有效性、先进性、优越性及实用性.

2 多目标优化问题

一般多目标优化问题的数学描述为

$$\min F(X) = (f_1(X), f_2(X), \dots, f_l(X))^T,$$
$$X = (x_1, x_2, \dots, x_d)^T,$$
$$\text{s.t. } g_u(X) \leq 0, \quad u = 1, 2, \dots, p;$$
$$h_v(X) = 0, \quad v = 1, 2, \dots, q.$$

(1)

其中: $F(X)$ 为一个包含 l 个子目标的多目标优化问题; $X = (x_1, x_2, \dots, x_d)^T \in R^d$ 为决策变量, d 为决策变量的维数; $f_l(X)$ 为第 l 个目标函数; $g_u(X)$ 为第 u 个不等式约束; p 为不等式约束的个数; $h_v(X)$ 为第 v 个等式约束; q 为等式约束的个数.

定义 1 对于任意两个自变量 a 和 b ,有

$$\begin{cases} a \succ b(a \text{ dominates } b), & f(a) < f(b); \\ a \succ_w b(a \text{ weakly dominates } b), & f(a) \leq f(b); \\ a \sim b(a \text{ indifferent } b), & f(a) = f(b); \\ f(a) \neq f(b) & f(b) \neq f(a). \end{cases}$$

定义 2 对于一个自变量 $x \in X$,考虑 X 的一个子集 A ,如果 $\exists a \in A, a \succ x$,则 x 称为对应于集合 A 的 Pareto 最优.

定义 3 MOP 问题中所有 Pareto 最优解的集合称为 Pareto 最优集;Pareto 最优集的目标值构成

的区域称为 Pareto 最优前沿.

多目标问题在求解过程中很难找到一个解,使每个目标同时达到最优.所以,多目标优化问题不同于单目标优化问题,其最优解往往不是单一的,而是一组解的集合.智能多目标优化算法的主要工作是:构造非支配集,并使非支配集不断逼近问题真正的 Pareto 最优前沿,最终达到最优.

3 标准粒子群算法

PSO 求解优化问题时,问题的解对应于搜索空间中一个“粒子”.每个粒子都有自己的位置和速度(决定飞行的方向和距离)及一个由被优化函数决定的适应值.各个粒子记忆、追随当前的最优粒子,在解空间中搜索.每次迭代中,粒子通过跟踪两个“极值”来更新自己的位置和速度:一个是粒子本身所找到的最好解,叫作个体极值($p_{best}^k_{id}$);另一个是整个粒子群中所有粒子在历代搜索过程中所达到的最优解(g_{best}^k).基本 PSO 算法中,速度更新公式和位置更新公式分别为

$$v_i^{k+1} = wv_i^t + c_1r_1(p_{best}^k_{id} - x_{id}^k) +$$
$$c_2r_2(g_{best}^k - x_{id}^k),$$

(2)

$$x_{id}^{k+1} = x_{id}^k + v_i^{k+1}.$$

(3)

其中: $i = 1, 2, \dots, m$, m 为粒子群中粒子的个数; $d = 1, 2, \dots, n$, n 为解向量的维数; $k = 1, 2, \dots, k_{max}$, k_{max} 为最大迭代次数; c_1 和 c_2 为加速正常数; w 为惯性权重; r_1 和 r_2 为 $[0, 1]$ 之间的随机数.

4 基于两阶段领导的多目标粒子群算法

多目标进化算法需保证 Pareto 前沿的收敛性和多样性特征,因此将单目标 PSO 改造为 MOPSO,关键是设置合理的 Pareto 集多样性维持策略和粒子群全局最优值更新操作.下面给出本算法的具体实现步骤.

4.1 P-AMOPSO 算法流程

P-AMOPSO 算法流程如图 1 所示.具体过程如下:

- Step1: 初始化算法参数,包括进化种群大小 MP,外部集大小 MA,PSO 参数 c_1, c_2 和 $w, t = 0$,高斯变异概率、均匀变异概率、最大迭代次数等;
- Step2: 随机初始化进化种群 P 与外部种群 A ;
- Step3: 令 $t = t + 1$,迭代计算,开始循环;
- Step4: 将 P 与 A 结合后根据强支配关系及拥挤距离排序的原则重新划分 P 与 A ;
- Step5: 在 A 集中根据分阶段领导粒子选择策略选择领导粒子(G_{best});
- Step6: 更新粒子的速度及位置;
- Step7: 根据高斯与均匀相结合的变异策略对

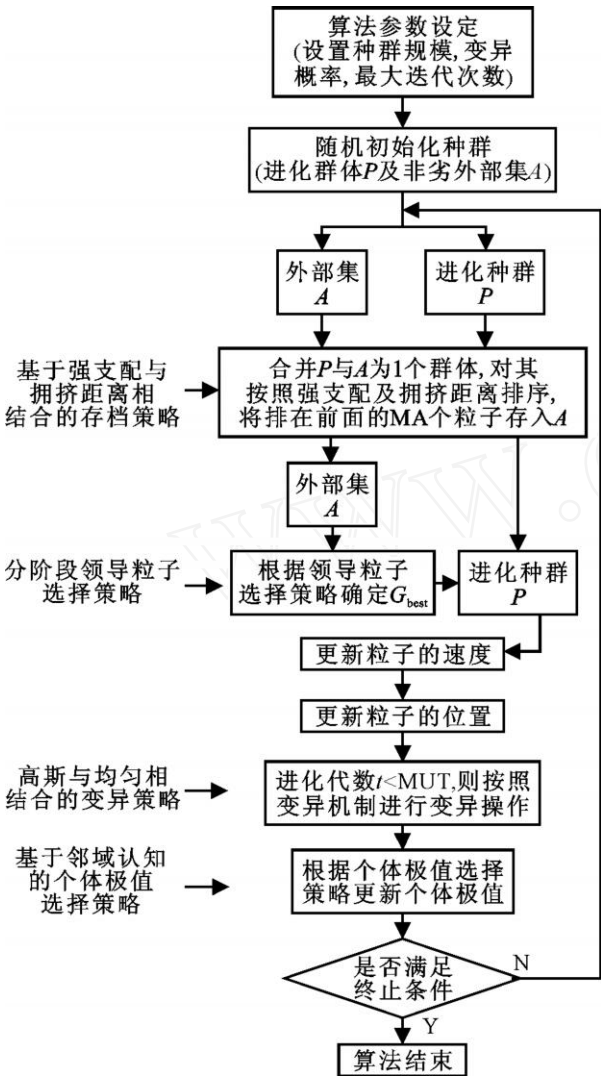


图 1 P-AMOPSO 算法流程图

P 集中的部分粒子进行变异；

Step8：根据基于邻域认知的个体极值更新策略更新个体极值（ P_{best} ）；

Step9：判断是否满足终止条件，满足则将 A 集的粒子作为 Pareto 最优解集输出，否则返回 Step3.

4.2 基于强支配与拥挤距离相结合的外部集存档策略

PSO 算法没有选择机制，种群随进化代数连续变化，必须使用外部种群保持所求非劣解，其作用有二：一是作为算法的输出，构成最终的 Pareto 前沿；二是作为微粒群的领导集合，引导整个群的进化。因此，外部档案的作用非常重要，既要引导微粒群向着准确 Pareto 前沿移动，也要保持种群的多样性，使得微粒在整个 Pareto 前沿上分布均匀。

4.2.1 强支配关系

引入强支配关系可使各个粒子保持一定距离，有效控制粒子的聚合程度，有助于保持粒子群的多样性。强支配关系的定义为：1) 如果粒子 $A \succ B$ ，则认为 $A \succ_{\text{强}} B$ ；2) 对于 $A \sim B$ ， \forall 目标函数 m ，如果

有 $|f_m^A - f_m^B| < \epsilon_m$ ， ϵ_m ($m = 1, 2, \dots, k$) 为正常数，则随机选择 A 或 B；如果 A 被选中，则认为 $A \succ_{\text{强}} B$ ，反之亦然。由支配关系转化为强支配的示意图如图 2 所示。




图 2 支配关系转化为强支配关系示意图

如果 ϵ_m 取值过小，则强支配关系的作用就会变小，当 $\epsilon_m = 0$ 时，强支配关系退化为支配关系；如果 ϵ_m 取值过大，强支配关系变强，则粒子变得过于稀疏。本文利用经验公式取 ϵ_m 值为

$$\epsilon_m = \frac{f_m^{\max} - f_m^{\min}}{C}$$

(4)

其中 C 为强支配系数。对于 2 个目标函数的优化问题， $C > 80$ ；对于有 2 个以上目标函数的优化问题， $C \in [20, 30]$ 。原则上，目标越多， ϵ_m 的取值相对越大。

4.2.2 拥挤距离排序

群体中解的疏密程度可以通过个体的拥挤距离来判断。图 3 为点 i 拥挤距离示意图，其拥挤距离为所在立方体对应不同目标函数相邻点的边长（即相邻非劣解适应值之差）之和。拥挤距离越小，表明解的分布的越密集，解的多样性越小；反之，表明解分布的越稀疏，解的多样性越大。




图 3 拥挤距离示意图

4.2.3 外部集存档方案

具有连续 Pareto 前沿的一些问题有无穷多个 Pareto 解，不可能将他们全部保存起来，所以必须限制外部档案的大小。本算法直接指定外部集的大小，每次迭代开始时，将进化种群 P 与外部集 A 结合为一个群体。对这个群体先进行基于强支配关系的非劣排序，再进行拥挤距离排序，强支配关系优先，由大到小排列，选择前 MA 个粒子进入 A 集，余下粒子进入 P 集，这样可以保证 A 集的领导性和多样性。

4.3 分阶段领导粒子选择策略

领导粒子的选取是 PSO 算法的核心，对于求解 MOP 问题，这个领导粒子关系到算法的收敛速度、解的多样性等。在进化的不同阶段，可以用不同的方法选择领导粒子，以满足多目标优化算法对于收敛

速度及多样性的要求^[14]. 本文设计了一种分阶段领导粒子选择策略,即在群体进化的前半阶段采用收敛速度极快的 Sigma 领导方法,找到一个近似的 Pareto 前沿;然后,在余下的阶段采用本文所提出的基于理想最优粒子的外部集领导粒子选择方法,促进种群多样性,进行深度寻优. 这样既保证了算法的快速收敛,又保证了解的多样性.

4.3.1 Sigma 方法

Mostaghim 等^[15]提出了基于 Sigma 值的领导选择方法,其基本思想是:赋予群和外部档案中每个粒子一个 Sigma 值,可定义粒子的 Sigma 值. 二维为

$$= \frac{f_1^2 - f_2^2}{f_1^2 + f_2^2}; \tag{5}$$

三维为

$$= \begin{bmatrix} f_1^2 - f_2^2 \\ f_2^2 - f_3^2 \\ f_3^2 - f_1^2 \end{bmatrix} / (f_1^2 + f_2^2 + f_3^2). \tag{6}$$

每个粒子选择外部档案中与其 Sigma 值最接近的粒子作为其领导(对三维问题求 $\| \cdot \|$). 该方法的优点在于能够加快算法的收敛速度,计算简单. 为防止由于目标函数值相差大而造成 值总是接近于 1 或 -1 的情况,对目标函数进行归一化处理,即

$$f_1 = \frac{f_1 - f_{1,\min}}{f_{1,\max} - f_{1,\min}}, \tag{7}$$

$$f_2 = \frac{f_2 - f_{2,\min}}{f_{2,\max} - f_{2,\min}}. \tag{8}$$

其中: $f_{1,\min}$ 和 $f_{2,\min}$ 分别为 f_1 和 f_2 的最小值; $f_{1,\max}$ 和 $f_{2,\max}$ 分别为 f_1 和 f_2 的最大值. 从而得到新的值为

$$= \frac{f_1^2 - f_2^2}{f_1^2 + f_2^2}. \tag{9}$$

4.3.2 理想最优粒子方法

定义 4^[16] 设 f_j^* 是第 j 个目标的最优值,点 $(f_1^*, f_2^*, \dots, f_n^*)$ 称为理想点,问题

$$\min (f(x)) = \sqrt[n]{\sum_{j=1}^n (f_j(x) - f_j^*)^2} \tag{10}$$

的最优解 x 就是理想最优解(理想最优粒子).

对于一个复杂的多目标优化问题,各个目标上的最优值及其对应的最优点往往事先不知,本文将迭代过程中找到的各个目标的历史最优值作为 f_j^* .

由已构造好的 A 集确定领导粒子依如下步骤完成:

- Step1: 在非支配解集中求出每个目标的最优极值 f_j^* 及最优极值粒子;
- Step2: 根据式(10),求得理想最优粒子;
- Step3: 计算最优极值粒子与理想最优粒子的

均值,并作为 G_{best} .

采用该均值作为领导粒子,代表了各个目标上的最优信息,既实现了算法的全局寻优,又有利于局部深度探索.

4.3.3 领导粒子选择方案

算法的前 m 代采用收敛速度极快的 Sigma 方法选择领导粒子,后 $n - m$ 代采用理想最优粒子的方法确定领导粒子.

4.4 高斯与均匀相结合的变异策略

粒子群算法具有快速收敛的特点,但在多目标算法中,过快的收敛速度反而可能导致算法早熟、陷入局部最优,收敛到错误的 Pareto 前端. 目前解决这个问题 的主要方法是引入变异机制,但变异方法往往带有较大的盲目性. 因此,盲目的变异有可能减缓算法的收敛速度. 基于以上考虑,本文提出了高斯分布与均匀分布相结合的变异策略. 其思想是:拥挤距离较大的粒子,采用促进种群收敛的高斯分布变异,实现局部寻优,降低粒子的拥挤距离,同时也保持了一定的摆脱局部极值的能力;拥挤距离较小的粒子,采用均匀分布变异重新初始化被变异维的值,使得粒子有机会在整个搜索范围内寻优,以便加快摆脱局部极值.

具体方案为:对群体进行拥挤距离排序,对于前 20% 的粒子,随机挑选一定数量的粒子进行高斯分布变异;对于后 20% 的粒子,随机挑选一定数量的粒子进行均匀分布变异;对于中间的粒子,随机挑选一定数量的粒子进行赌轮盘操作来确定进行哪种变异(各占 50%). 具体公式如下:均匀分布变异为

$$x_{id} = x_{\min,d} + \text{rand} \times (x_{\max,d} - x_{\min,d}), \tag{11}$$

高斯分布变异为

$$x_{id} = x_{id} (1 + \text{Gaussian}(\cdot)). \tag{12}$$

其中: $x_{\min,d}$ 和 $x_{\max,d}$ 分别为粒子在第 d 维上的最小值和最大值;rand 为 0 ~ 1 之间的随机数; σ 为 0 ~ 1 之间的小数,一般取 0.1; σ^2 为高斯分布的方差,一般取 0.1.

由于本算法有最优信息保存机制,不必担心变异后劣的粒子飞不回 Pareto 前沿.

4.5 基于邻域认知的个体极值选择策略

目前,学术界对 MOPSO 算法的研究往往忽略对个体极值更新的改进,通常采用支配关系更新个体极值. 而在进化过程中,需要较多进化代数个体极值才能更新,这不是因为该极值一定好,而是大多数情况因为不相关而无法更新,这也是造成早熟的原因之一. 从社会学角度出发,现实中个体对周围环境的认识是较强的(例如父母、同寝室的好友),即周围一定数目或一定区域内的其他个体信息对该粒子

是有很大影响的,可以认为他们之间的信息传递也是一种自我认知.

基于上述思考,本算法提出了基于邻域认知的个体极值更新策略,具体方案为:随机选择几个粒子作为该粒子邻域粒子,在该邻域范围内选择非劣个体极值与原极值进行比较,完成更新操作.具体更新方程为

$$v_i^{k+1} = v_i^t + c_1 r_1 (lp_{best_{id}}^k - x_{id}^k) + c_2 r_2 (G_{best_{id}}^k - x_{id}^k),$$

(13)

其中 lp_{best} 为邻域最优个体极值.

改进后的个体极值更新策略能够更好地提升算法性能,进一步增强抗早熟能力,增加了种群多样性,有利于粒子局部寻优.

5 仿真分析

5.1 测试函数及相关参数设置

本文针对两种有代表性的测试函数对本算法与基于拥挤距离排序的多目标方法(DC-MOPSO)^[12],基于多子群进化的多目标方法(MM-MOPSO)^[13]进行分析比较.对于 PSO 算法的参数, c_1 和 c_2 从 0.9 线性减小到 0.2; c_2 从 0.2 线性增加到 0.9;变异概率均为 0.5;强支配系数 C 为 80;进化种群及外部集的规模均为 200;最大迭代次数 n 依次为 1000;采用 Sigma 方法的前 m 次进化代数依次为 $0.3n, 0.4n, 0.5n, 0.7n$.

测试函数 1 (F_1) 为

$$\min f_1 = x^2, \min f_2 = (x - 2)^2,$$

$$x \in [-5, 7].$$

(14)

测试函数 2 (F_2) 为

$$\min f_1 = \begin{cases} -x, & x \leq 1; \\ -2 + x, & 1 < x \leq 3; \\ 4 - x, & 3 < x \leq 4; \\ -4 + x, & x > 4. \end{cases}$$

$$\min f_2 = (x - 5)^2.$$

$$x \in [-5, 10].$$

(15)

5.2 评价指标

为了评价算法的性能,采用以下评价指标对算法加以评价:

1) 收敛性指标

$$GD = \frac{1}{h} \sqrt{\sum_{i=1}^h d_i^2}.$$

(16)

2) 均匀性指标

$$SP = \sqrt{\frac{1}{h-1} \sum_{i=1}^h (\bar{P} - p_i)^2},$$

$$p_i = \min(|f_1^i(x) - f_1^1(x)| + |f_2^i(x) - f_2^1(x)|),$$

$$\bar{P} = \frac{1}{h} \sum_{i=1}^h p_i.$$

(17)

3) 运算时间为 T .

其中: h 为算法所得非劣解的个数, d_i 为第 i 个解到 Pareto 最优解集的最小距离, T 为进行优化计算所需要的时间.若 $GD = 0$,则表示所得非劣解均属于 Pareto 最优解集;若 GD 为其他值,则表示所求非劣解与 Pareto 最优值有所偏离.因此,该指标反映了算法所得的优化解集与 Pareto 最优解集的逼近程度, GD 值越小,逼近程度越好.若 $SP = 0$,则表示非劣解前端上所有解呈均匀分布,因此 SP 值越小,非劣解前端分布越均匀. T 越小说明算法的复杂度越小, T 越大说明算法的复杂度越大,本实验在 Core 2 DELL 计算机上运行.

5.3 结果分析

分别对两个测试函数应用 3 种算法运行 60 次.表 1 和表 2 分别为 P-AMOPSO 算法取不同 m 值时,与 DC-MOPSO 算法,MM-MOPSO 算法关于两个测试函数的 GD 均值与 SP 均值的对比.图 4 和图 5 为 $m = 0.4n$ 时 P-AMOPSO 算法与 DC-MOPSO 算法,MM-MOPSO 算法对于两个测试函数的收敛速度及生成 Pareto 前沿的对比.表 3 为 3 种算法的计算时间比较.

表 1 两个测试函数的 GD 均值

	m_1	GD 均值	
		F_1	F_2
P-AMOPSO	$0.3n$	0.0261	0.0328
	$0.4n$	0.0256	0.0325
	$0.5n$	0.0257	0.0318
	$0.7n$	0.0253	0.0329
DC-MOPSO		0.0312	0.0416
MM-MOPSO		0.0296	0.0375

表 2 两个测试函数的 SP 均值

	m_1	SP 均值	
		F_1	F_2
P-AMOPSO	$0.3n$	0.0243	0.0518
	$0.4n$	0.0276	0.0536
	$0.5n$	0.0377	0.0633
	$0.7n$	0.0652	0.0727
DC-MOPSO		0.0856	0.1245
MM-MOPSO		0.0485	0.0738

从表 1 和表 2 可以看出,无论在 GD 值还是 SP 值上,P-AMOPSO 方法都要好于 DC-MOPSO 和 MM-MOPSO 方法.这是由于本算法的后期使用了理想领导粒子来领导群体的进化,该理想领导粒子

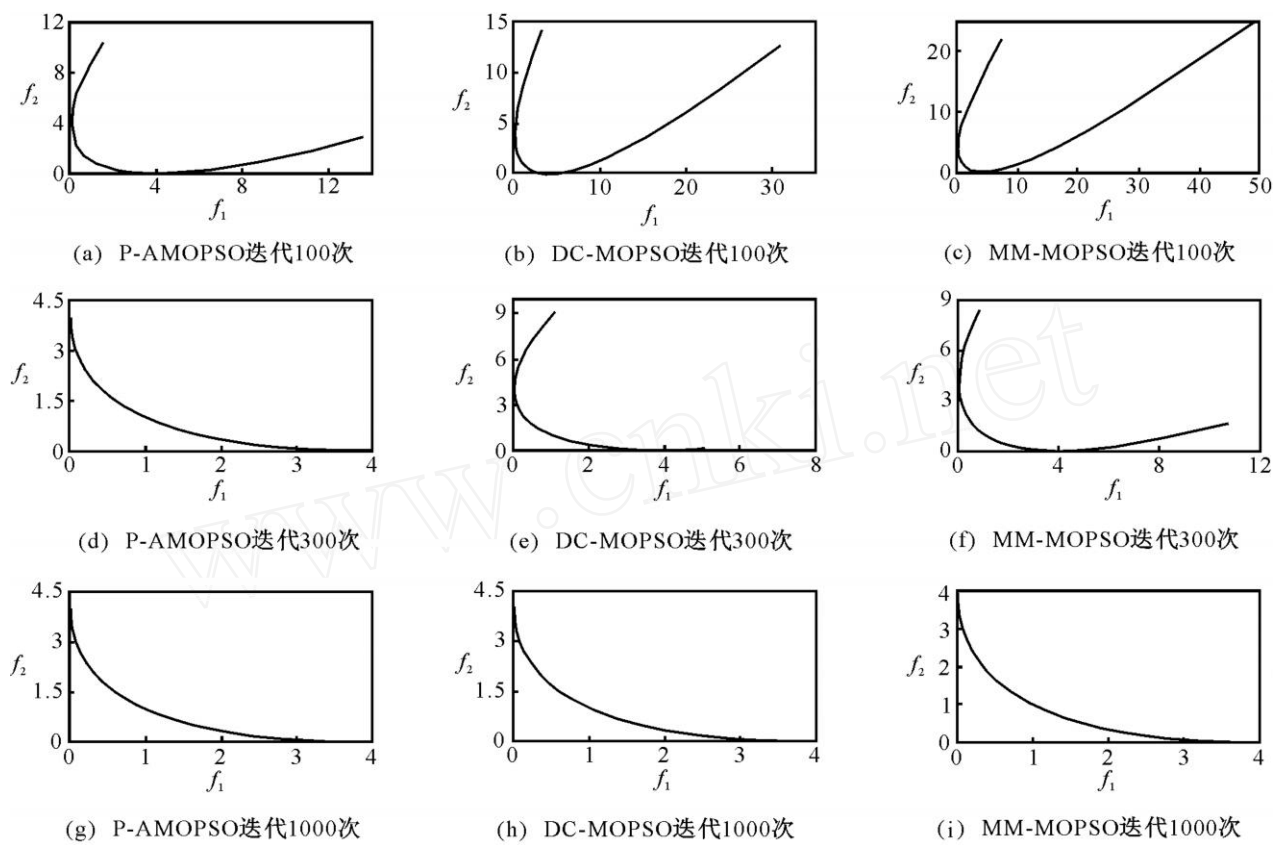


图 4 当 $n_1 = 0.4n$ 时,3 种算法关于 f_1 的 Pareto 曲线

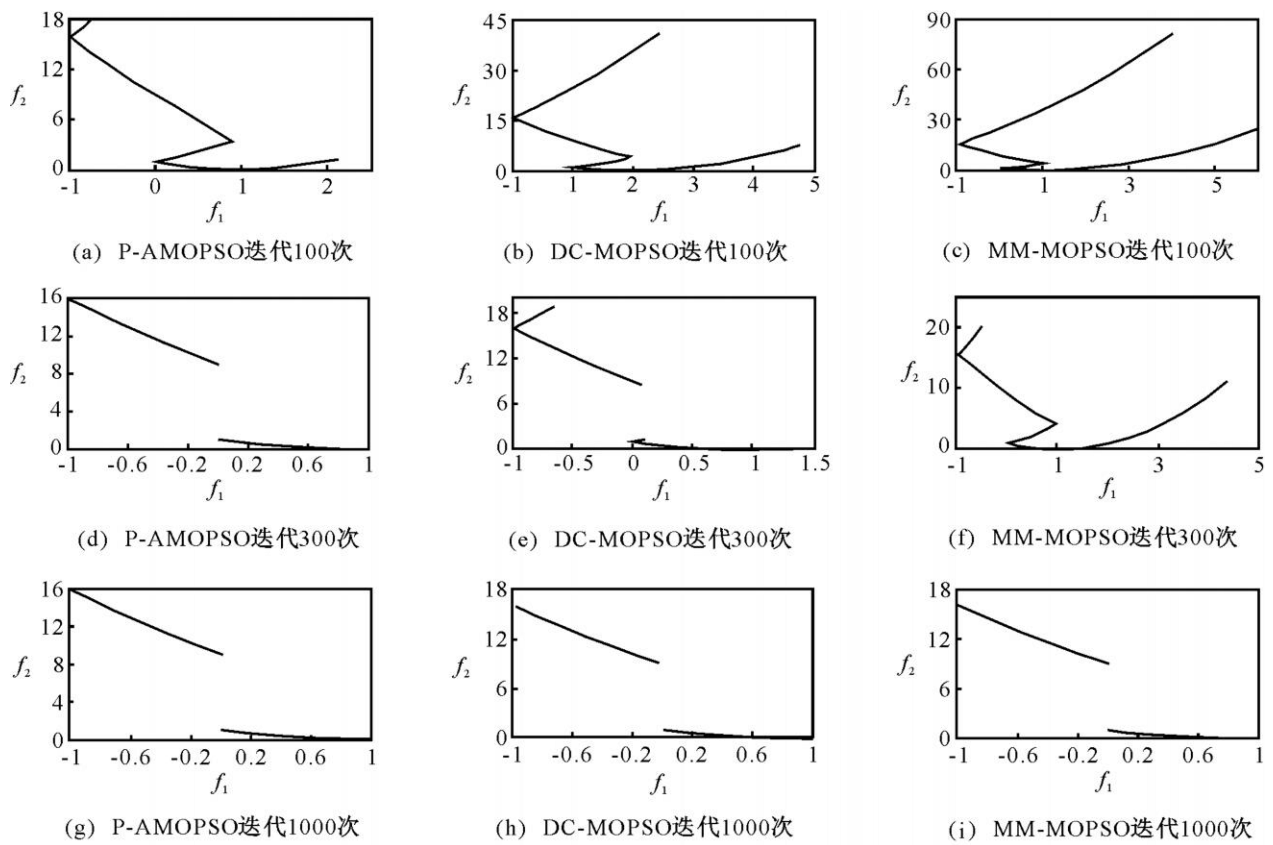


图 5 当 $n_1 = 0.4n$ 时,3 种算法关于 f_2 的 Pareto 曲线

代表了各个目标的最优信息,最后使得结果更加接近最优前沿, GD 值也就是最小的;采取的高斯分布与均匀分布相结合的变异策略,避免了变异的盲目性,使得最后解分布得更加均匀, SP 值也就相应地

表 3 3 种算法的计算时间 s

		迭代 100 次	迭代 300 次	迭代 1000 次
P-AMOPSO	F_1	25. 02147	79. 23451	261. 06065
	F_2	94. 25684	285. 21475	975. 804456
DC-MOPSO	F_1	15. 75210	48. 12402	156. 32472
	F_2	47. 32145	143. 21458	486. 21547
MM-MOPSO	F_1	17. 98413	56. 32142	182. 32011
	F_2	52. 12468	156. 32154	532. 21458

较小. 本文的 P-AMOPSO 方法在 m_1 取不同值时, GD 和 SP 也有所不同. 无论 m_1 取何值, GD 值的差异都不大,而 SP 值的差异较大. 当 $m_1 = 0.4n$ 时,要都好于 $m_1 = 0.5n$ 和 $n_1 = 0.7n$,而略差于 $m_1 = 0.3n$,但当 $m_1 = 0.3n$ 时的 GD 值大于 $m_1 = 0.4n$ 时的 GD 值. 因此,本文综合以上结果选择 $m_1 = 0.4n$.

当 P-AMOPSO 算法取 $m_1 = 0.4n$ 时,由图 4 和图 5 可以看出,DC-MOPSO 方法的收敛速度比 MM-MOPSO 方法快,但 MM-MOPSO 方法最后解的分布性比 DC-MOPSO 方法好. 对于一般的多目标方法,要么注重收敛速度,要么注重解的分布性,而从图中可以看出本文的 P-AMOPSO 方法兼顾了两方面的要求,既保证了粒子快速收敛,又保证了解的多样性,显示了本算法的优越性.

由表 3 可以看出,相同的计算代数下,本文 P-AMOPSO 算法的计算时间比其他两个算法的计算时间长,这是由于在构造外部集和进行有选择的变异时,都要进行排序,这样就增加了一定的计算量,延长了计算时间. 但是,本文 P-AMOPSO 算法的收敛速度很快,在 300 代时就已经收敛,而其他两个算法都需要 800~1000 代时才能收敛,收敛时间比本算法时间长. 因此,本算法在一定程度上也减少了计算时间.

6 结 论

本文提出了一种基于分阶段领导与交叉变异相结合的多目标粒子群算法. 该算法包含 4 个改进策略:基于强支配排序与拥挤距离排序相结合的策略构造外部集,不但保证了算法最后输出解的有效性,而且促进了种群的多样性;基于分阶段的领导粒子选择策略,既保证了算法的收敛速度,又保证了解的均匀性;基于高斯分布及均匀分布相交叉的变异策略,对于拥挤距离不同的粒子采用不同的变异策略,既克服了早熟,又避免了因盲目变异而造成降低算法性能的结果;基于邻域认知的个体极值更新策略,有利于粒子局部寻优. 将其应用于两个测试函数,并与 DC-MOPSO 方法和 MM-MOPSO 方法进行分析对比,结果表明所提出的算法具有良好的性能.

参考文献(References)

[1] Li X D. A nondominated sorting particle swarm optimizer for multiobjective optimization [J]. Lecture Notes in Computer Science, 2003, 2723: 37-48.

[2] Xiong S W, Liu L, Wang Q, et al. Improved multi-objective particle swarm algorithm [J]. J of Wuhan University, 2005, 51(3): 308-312.

[3] Alvarez-benitez J, Everson R. A MOPSO algorithm based exclusively on Pareto dominance concepts [J]. Lecture Notes in Computer Science, 2005, 3410: 459-473.

[4] 金欣磊, 马龙华. 基于动态交换策略的快速多目标粒子群优化算法研究[J]. 电路与系统学报, 2007, 12(2): 78-83.

(Jin X L, Ma L H. A fast multi-objective particle swarm optimization based on dynamic exchange strategy [J]. J of Circuits and Systems, 2007, 12(2): 78-83.)

[5] 雷德明, 吴智铭. Pareto 档案多目标粒子群优化[J]. 模式识别与人工智能, 2006, 19(4): 475-480.

(Lei D M, Wu Z M. Pareto archive multi-objective particle swarm optimization[J]. Pattern Recognition and Artificial Intelligence, 2006, 19(4): 475-480.)

[6] Coello Coello C A, Pulido G T, Lechuga M S. Handling multiple objectives with particle swarm optimization[J]. IEEE Trans on Evolutionary Computation, 2004, 8(3): 256-279.

[7] Li X D. Better spread and convergence: Particle swarm multi-objective optimization using the maximin fitness function[C]. Proc of the Genetic and Evolutionary Computation Conf. Heidelberg, 2004: 117-128.

[8] Vlachogiannis J G, Lee K Y. Determining generator contributions to transmission system using parallel vectorevaluated particle swarm optimization[J]. IEEE Trans on Power Systems, 2005, 20(4): 1765-1774.

[9] Alvarez-Benitez J E, Everson R M, Fieldsend J E. AMOPSO algorithm based exclusively on pareto dominanceconcepts [C]. The 3rd Int Conf on Evolutionary Multi-criterion Optimization. Guanajuato: LNCS, 2005: 459-473.

[10] 张利彪, 周春光. 基于粒子群算法求解多目标优化问题[J]. 计算机研究与发展, 2004, 41(7): 1286-1291.

(Zhang L B, Zhou C G. Solutions of multiobjective optimization problems based onparticle swarm optimization [J]. J of Computer Research and Development, 2004, 41(7): 1286-1291.)

[11] Janga M, Nagesh D. Multi-objective particle swarmoptimization for generating optimal trade-offs in reservoiroperation [EB/ OL]. <http://www.interscience.wiley.com>, 2007-03-27.

(下转第 415 页)

- Designing and evaluating sustainable logistics networks [R]. Rotterdam, 2006.
- [2] Daniel. The challenge of closed-loop supply chains[J]. Interfaces, 2003, 33(6): 3-6.
- [3] Guide Jr V D R, Jayaraman V, Linton J D. Building contingency planning for closed loop supply chains with product recovery [J]. J of Operations Management, 2003, 21(3): 259-279.
- [4] Samee K, Malegeat P. Strategic alliance in a closed-loop supply chain [J]. Technological Innovation, 2006, 26(10): 1127-1135.
- [5] Gupta S M, Pochampally K K. Crucial issues in closed-loop supply chain design[C]. The 2nd World Conf. on POM and 15th Annual POM Conf. Cancun: Mexico, 2004.
- [6] Patroklos G, Dimitrios V. The effect of environmental parameters on product recovery [J]. European J of Operational Research, 2004, 15(2): 449-464.
- [7] Dimitrios V, Patroklos G, Eleftherios I. A system dynamics model for dynamic capacity planning of remanufacturing in closed-loop supply chains [J]. Computers and Operations Research, 2007, 43(2): 367-394.
- [8] 孙林岩, 王蓓. 逆向物流的研究现状和发展趋势[J]. 中国机械工程, 2005, 16(10): 928-934.
(Sun L Y, Wang B. State-of-the-art in reverse logistics researches[J]. China Mechanical Engineering, 2005, 16(10): 928-934.)
- [9] Pasternack B. Optimal pricing and returns policies for perishable commodities[J]. Marketing Science, 1985, 4(2): 166-176.
- [10] Nakashima K, Arimitsu H, Nose T, et al. Optimal control of a remanufacturing system [J]. Int J of Production Research, 2004, 42(7): 3619-3625.
- [11] 顾巧论, 高铁杠, 石连栓. 基于博弈论的逆向供应链定价策略分析[J]. 系统工程理论与实践, 2005, (3): 20-25.
(Gu Q L, Gao T G, Shi L S. Price decision analysis for reverse supply chain based on game theory [J]. Systems Engineering—Theory and Practice, 2005, (3): 20-25.)
- [12] Savaskan R C, Bhattacharya S, Wassenhove V L N. Closed-loop supply chain models with product remanufacturing[J]. Management Science, 2004, 50(2): 239-252.
- [13] 王玉燕, 李帮义, 申亮. 供应链、逆向供应链系统的定价策略研究[J]. 中国管理科学, 2006, 14(4): 40-45.
(Wang Y Y, Li B Y, Shen L. The price decision model for the system of supply chain and reverse supply chain [J]. Chinese J of Management Science, 2006, 14(4): 40-45.)
- [14] 葛静燕, 黄培清. 价格相依的闭环供应链渠道选择和协调策略[J]. 工业工程与管理, 2007, 12(1): 29-34.
(Ge J Y, Huang P Q. The research of closed-loop supply chain coordination [J]. Industrial Engineering and Management, 2007, 12(1): 29-34.)
- [15] Maltz A B. The relative importance of cost and quality in the outsourcing of warehousing [J]. J of Business Logistics, 1994, 15(2): 45-62.
- [16] 葛静燕, 黄培清, 王子萍. 基于博弈论的闭环供应链协调问题[J]. 系统管理学报, 2007, 16(5): 549-552.
(Ge J Y, Huang P Q, Wang Z P. Closed-loop supply chain coordination research based on game theory[J]. J of Systems and Management, 2007, 16(5): 549-552.)

(上接第 410 页)

- [12] 王辉, 钱锋. 基于拥挤度与变异的动态微粒群多目标优化算法[J]. 控制与决策, 2008, 23(11): 1238-1242.
(Wang H, Qian F. Improved PSO-based multi-objective optimization by crowding with mutation and particle swarm optimization dynamic changing [J]. Control and Decision, 2008, 23(11): 1238-1242.)
- [13] 张利彪, 周春光. 求解多目标优化问题的一种多子群体进化算法[J]. 控制与决策, 2008, 23(11): 1313-1316.
(Zhang L B, Zhou C G. A multiple subswarms evolutionary algorithm for multi-objective optimization problems[J]. Control and Decision, 2008, 23(11): 1313-1316.)
- [14] 郑向伟. 求解优化问题的微粒群算法及其应用研究[D]. 济南: 山东师范大学, 2008.
(Zheng X W. Researches on particle swarm optimizers and their applications [D]. Ji 'nan: Shandong Normal University, 2008.)
- [15] Mostaghim S, Teich J. Strategies for finding good local guides in multi-objective particle swarm optimization [C]. Proc of the 2003 IEEE Swarm Intelligence Symposium. Indianapolis: IEEE Service Center, 2003: 26-33.
- [16] 莫愿斌, 陈德钊. 多目标过程系统优化的粒子群算法求解[J]. 高校化学工程学报, 2008, 22(1): 94-95.
(Mo Y B, Chen D Z. Particle swarm optimization for multi-objective process system optimization problems [J]. J of Chemical Engineering of Chinese Universities, 2008, 22(1): 94-95.)